

IMT Atlantique
Dépt. Signal & Communications
Technopôle de Brest-Iroise - CS 83818
29238 Brest Cedex 3
Téléphone : +33 (0)2 29 00 13 04
Télécopie : +33 (0)2 29 00 10 12
URL : www.imt-atlantique.fr



Rapport intermédiaire

Projet 3A IMSAT

CIOCARLAN Alina
MCE

EL MADRAJ Nordin
ILSD

LEMERLE Gaspard
OPE

ROUSSE Basile
DaSci

VAUCHER Marie
ASCy

Date d'édition : 22 mars 2021



IMT Atlantique
Bretagne-Pays de la Loire
École Mines-Télécom

Sommaire

1. Introduction	3
2. Résultats	4
2.1. Embarquabilité et énergie	4
2.2. Données	7
2.2.1. Sentinel-2	7
2.2.2. Planet	8
2.2.3. Création d'un dataset : Simplastic	8
2.3. Algorithmes d'IA	10
2.3.1. K-means et spectral unmixing	10
2.3.2. KNN et Naive Bayes	11
2.3.3. Tests d'hypothèses	13
2.3.4. Théorie des graphes - spectral clustering	22
3. Comparatif des méthodes utilisées	26
3.1. Critère d'évaluation de la qualité des prédictions	26
3.2. Tableau comparatif	27
4. Conclusion	29
5. Lien vers les codes	29
Références	30

Liste des figures

1.	Ratio des algorithmes de compression en fonction des années et de leurs technologies	5
2.	Carte de développement jetson nano avec algorithme de tracking et utilisation des cpu	6
3.	Réflectivité de l'eau en fonction de sa distance à la côte	9
4.	Image et son label issus du dataset final	9
5.	Signatures spectrales extraites : eau et plastique	10
6.	Résultats obtenus après un premier spectral unmixing	11
7.	Matrice de Corrélation pour l'algorithme Naïve Bayes	12
8.	Segmentation d'une image avec un Kmeans à 2 classes	13
9.	Segmentation d'une image avec un Kmeans à 8 classes	14
10.	Anomalies pour chaque bande spectrale	14
11.	Anomalies sur plusieurs bandes spectrales	15
12.	Histogrammes partie 1	16
13.	Histogrammes partie 2	16
14.	Courbes PFA et PD, image 0	17
15.	Courbe ROC image 0	17
16.	Histogrammes statistiques, image 0	17
17.	Résultats image 0	18
18.	Résultats image 1	18
19.	Résultats image 5	18
20.	Histogramme de l'eau comparé à la valeur des moyenne des pixels plastique dans ces images	19
21.	Second test d'hypothèse appliqué à l'image image 0 VS label	20
22.	Image 0 : Gradient à gauche, Laplacien à droite	20
23.	Image 5 : Résultats test d'hypothèse sur le gradient	21
24.	Image 5 : Résultats test d'hypothèse sur le laplacien	21
25.	Image 5 : Résultats test d'hypothèse sur une image Planet	21
26.	Image dans le spectre visible (gauche) et bande spectrale B08 pré-traitée (droite) des cibles plastiques	24
27.	Masques de segmentation avec, de gauche à droite, la création d'un graphe avec 50,100 et 150 plus proches voisins	24
28.	Image Planet des cibles plastique, son label et la prédiction du spectral clustering.	25

Liste des tableaux

1.	Bandes spectrales du capteur de sentinel-2	7
2.	Bandes spectrales du capteur de Planetscope	8
3.	Comparatif des méthodes utilisées	27

1. Introduction

Le plastique est aujourd’hui connu de tous. Ce matériau a vu son essor lors des années 1950, au sortir de la Seconde Guerre Mondiale. Ses propriétés physiques si particulières (facilité à travailler, durabilité, solidité,...), son faible coût, sa polyvalence permettent aux industriels de l’utiliser presque partout. Il se retrouve dans presque tous les objets qui nous entourent, et fait partie intégrante de nos vies : des bouteilles, des sacs, des vêtements, des jouets, de l’électronique... Il permet de soulager l’industrie, de produire toujours plus, de faire face à la demande ; sa production n’a pas de raison de s’arrêter... Elle explose : de 180 millions de tonnes métriques produites par an en 1990, on arrive en 2018 à plus de 360 millions de tonnes de plastique par an, soit le double. Le problème, c’est que cet essor s’accompagne aussi d’une réalité bien moins attrayante : l’explosion de la quantité de déchets plastiques. Certains tentent bien de les recycler, mais la réalité est tout autre : seulement 10% des déchets plastiques sont recyclés. En ce qui concerne les 90% restant, ils sont malheureusement destinés à se répandre dans la nature. Tous ces plastiques rejetés par l’homme n’ont aujourd’hui qu’un avenir : ils sont charriés par les pluies, les eaux, les tempêtes, les vents, les fleuves, et terminent dans nos océans, sur nos littoraux, s’il n’y ont pas été directement déversés par nos bateaux ou nos touristes sur les plages.

La pollution des océans est un problème de taille que nous devons à tout prix essayer de résoudre. Les plastiques mettent plusieurs centaines d’années à se décomposer. Ils peuvent flotter à la surface de l’eau, ou s’entasser sur nos fonds marins. Le problème est qu’ils détruisent l’environnement dans lequel ils se trouvent. Les plastiques les plus gros, les macroplastiques, se décomposent avec le temps en microplastiques. Ils sont inévitablement ingérés par la faune marine : ils empoisonnent les animaux, causent des problèmes physiques ou physiologiques, empêchent certains individus de se développer. Ces plastiques mettent en danger la faune marine, ce qui inquiète la communauté scientifique, mais surtout risquent de déstabiliser les chaînes alimentaires, ce qui peut avoir des conséquences désastreuses pour la survie de certaines espèces, dont l’homme.

Revenons un instant sur l’origine de ces microplastiques, pour mieux cerner les solutions qui s’offrent à nous. Ce sont les plastiques de petite taille (inférieure à 5mm), qui sont issus de la décomposition des macroplastiques. Si repérer les microplastiques semble être une tâche impossible, remonter à leur source peut être une solution viable. On peut d’abord agir en amont, en limitant la production de plastique, ou en rendant le plastique biodégradable et le plus inoffensif pour l’environnement. On peut aussi tenter de récupérer les macroplastiques avant que ceux-ci ne se dégradent. Cette solution est envisageable, puisque les macroplastiques ont tendance à s’agglutiner pour former des amas plus gros, flottant à la surface ou juste sous la surface de l’eau ; et elle est d’ores et déjà envisagée par plusieurs projets : The Sea Cleaners avec le bateau Manta, l’Ocean Cleanup Project qu’il s’attelle au continent de plastique, Seaqual ou encore Aquafil. Ces méthodes ont déjà fait leurs preuves, mais une information importante manque toujours pour rendre cette tâche plus facile et plus robuste : la localisation du plastique dans nos océans. Si certains tentent de les détecter à partir de bateaux, des littoraux, de drones, ou encore directement avec des capteurs submergés, aucune de ces méthodes ne permet d’avoir une vision systémique globale de l’évolution des plastiques, en temps presque réel. La solution que nous avons explorée est l’utilisation des données spatiales, qui permettraient de répondre à cette problématique. Si aucun satellite n’a été dédié à l’observation des plastiques flottants, des recherches ont été menées pour parvenir à la détection de plastique depuis l’espace.

Voici les apprentissages que nous avons retenus, et utilisés par la suite :

- Les images satellites brutes ne peuvent pas être utilisées directement. Celles-ci ont besoin d’être traitées et triées pour corriger différents effets atmosphériques (absorption par certaines molécules de l’atmosphère, diffusion par des aérosols, présence de nuages...). Les images disponibles en ligne, Sentinel-2 ou Planet par exemple, ont déjà été traitées.
- La résolution des images est un facteur discriminant dans le traitement d’images satellites, et surtout dans l’extraction d’informations utiles. La résolution d’une image satellite correspond à la dimension de la cellule terrestre réelle observé couverte par un pixel : pour une image de 10m*10m de résolution, chaque pixel contient l’information réfléchie par une parcelle terrestre carrée de 10

2. Résultats

mètres de côté.

- Dans le cadre d'imagerie satellite, et plus particulièrement d'imagerie multispectrale, il nous faut sélectionner les bandes spectrales qui peuvent nous permettre de discerner le plastique de son environnement. En ce qui concerne les plastiques, il s'agit des bandes qui se situent dans le spectre visible, et celle du proche infrarouge.
- Pour arriver à bien faire ressortir le plastique, on crée des combinaisons linéaires des différentes bandes spectrales : ce sont les indices. Leur détermination repose sur la différence de réflectance des matériaux à différentes longueurs d'onde. Plusieurs indices sont disponibles dans la littérature. Citons ici ceux qui donnent de bons résultats : le FDI (Floating Debris Index), le PI (Plastic Index), ou encore le NDVI (Normalised Difference Vegetation Index).

Nous détaillerons par la suite, dans la section 2.3 les algorithmes utilisés pour la détection de plastique à partir de ces images multispectrales.

Le traitement des images capturées par le satellite peut s'effectuer de deux manières différentes :

- Faire tourner les algorithmes d'intelligence artificielle au sol en utilisant les photos qui seront prises par le satellite IMSat et envoyées vers la station sol.
- Embarquer les algorithmes à bord du satellite IMSat afin de détecter le plastique directement depuis ce dernier et de ne transmettre que les positions du plastique détecté à la station au sol.

Après avoir mené une étude sur l'état de l'art, nous constatons que les algorithmes d'IA embarqués à bord des satellites sont extrêmement rares voire inexistant. En contactant des professionnels du sujet, plusieurs réponses ont été apportées. D'abord, ceci est une question d'habitude, les satellites ne sont pas utilisés comme des ordinateurs mais plutôt comme des relais d'informations. Ils reçoivent et envoient des données en permanence et stockent très peu de données ; par exemple la sonde Rosetta n'avait que 4Mo de mémoire embarquée lors de sa mission. Deuxièmement il s'agit d'une question de fiabilité, les algorithmes ne sont pas assez fiables pour que la mission repose entièrement sur eux surtout au vu des sommes financières engagées pour ces projets. Il y aussi le coût et la résistance de systèmes électroniques en milieu "hostile" (rayonnement cosmique, température,...). Ces différents points expliquent que les calculs soient uniquement faits au sol lors des différentes missions spatiales.

2. Résultats

2.1. Embarquabilité et énergie

Les demandes en informations provenant de l'espace (images satellitaires...) sont toujours plus grandes mais les technologies doivent présenter une grande robustesse pour éviter tout échec de la mission, car on ne peut pas faire revenir le matériel en cas de problème(s). Les technologies sont donc très anciennes par rapport à ce qui peut être utilisé sur Terre. De manière générale, nous remarquons que ces technologies de communication représentent un frein à la transmission de données des satellites.

Quelles sont les contraintes de télécommunication concernant notre projet CubeSat ?

Contrairement aux satellites lancés par de grands groupes, le CubeSat ne communiquera avec une unique station au sol. De plus, notre nanosat se trouvera sur une orbite dite LEO (Low Earth Orbit) de 300km ce qui est extrêmement bas. A partir de ces informations nous pouvons calculer une fenêtre de communication avec notre station sol. Nous estimons que la communication devrait être possible pendant 2 minutes lors de chaque passage. Sachant que le CubeSat devrait effectuer environ 15 passages au-dessus de la station par jour, on peut estimer le temps de communication à 30 min par jour entre le satellite et la station sol.

Quel volume de données devons-nous échanger avec la station sol ?

Afin de réaliser la détection de plastique dans les océans, les algorithmes développés nécessitent une banque d'images prises par le satellite. La résolution désirée minimale afin de pouvoir exploiter une photo

2. Résultats

est : 10mx10m pour un pixel et le mieux serait 3mx5m. Avec une telle résolution, chacune des photos prises par le satellite devrait avoir une taille de 200Mo. Afin de pouvoir correctement exécuter les algorithmes il faudrait recevoir au minimum environ 100 photos d'une même zone.

Quelles sont les performances de notre système de télécommunication ?

Le protocole de communication LoRaWan que nous utilisons sur IMSAT possède un débit de 300kBits/s ce qui donne environ 30Mo par passage. Nous en déduisons que nous avons un volume d'échange de 540Mo par jour soit environ deux photos. Après cette étude rapide nous constatons donc qu'il n'est pas envisageable de reposer sur l'envoi de ces photos par le satellite pour faire la détection du plastique au sol. Nous envisageons donc de faire un pré-traitement des données à bord du satellite. Une première idée serait de compresser les images. Après un état de l'art des différents algorithmes de compression qui existent, nous constatons que les ratios se situent entre 2 et 4 en fonction de la technologie utilisée ce qui nous permettrait d'obtenir 5 à 10 photos par jour, ce qui resterait insuffisant.

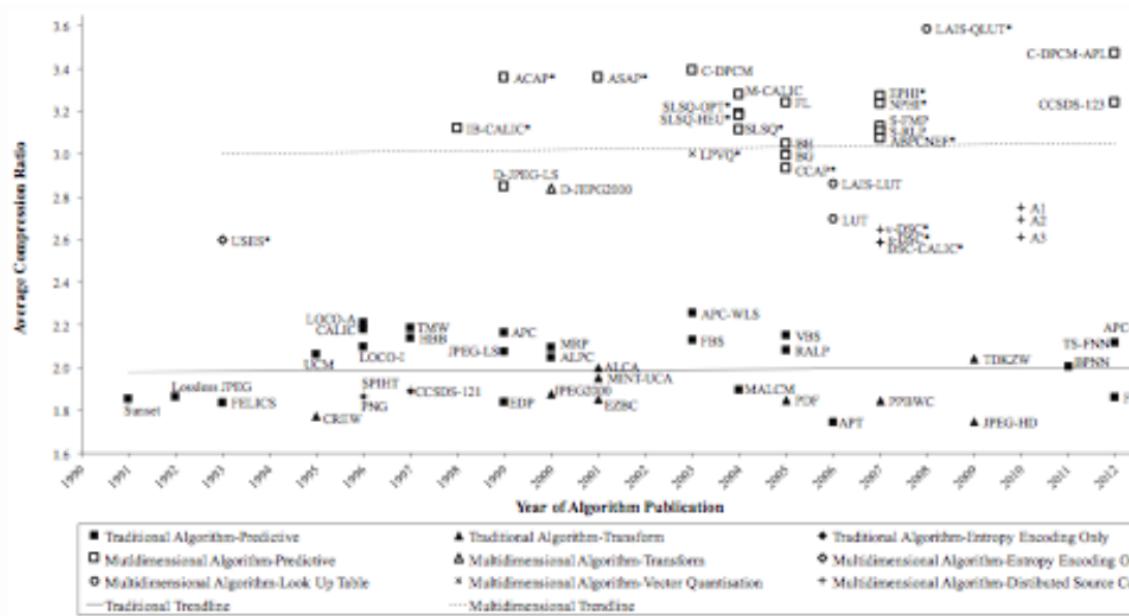


FIGURE 1 – Ratio des algorithmes de compression en fonction des années et de leurs technologies

Une seconde idée serait de repérer directement des photos qui seraient inexploitables et de les supprimer avant de les envoyer. Un critère éliminatoire pour l'exploitation des photos est la présence de nuages. L'idée serait donc d'embarquer un algorithme qui permet de repérer les photos comportant des nuages sur les images, ce qui est donc du ressort de l'autre équipe quant à la faisabilité.

Ces deux idées, bien que intéressantes, nous permettent d'améliorer nos échanges avec la station que de manière limitée, puisqu'il faut également ajouter que chaque photo doit être envoyée deux fois pour des questions de fiabilité du système de communication.

Nous avons alors l'idée de séparer le processus du traitement de l'image en deux : faire la partie entraînement de l'algorithme au sol et la prédiction au bord du satellite. Puisque l'apprentissage nécessite une grande puissance de calcul et surtout n'est pas à coût constant : l'algorithme demande toujours plus de place, il n'est pas approprié pour être embarqué à bord du satellite. Une fois l'entraînement réalisé, l'algorithme fournit une matrice de prédiction, qui peut alors être envoyée à bord du satellite, puisque le système de télécommunication est apte à recevoir des informations. Les algorithmes de prédiction sont eux à coût constant.

Cependant comment initialiser le processus ? En effet, comment réaliser la matrice de prédiction au sol sans photo ? Il est possible d'utiliser les images fournies par d'autres sociétés qui font de l'imagerie satellitaire en leur achetant leur données. Il faut cependant que nous utilisions le même capteur afin que

2. Résultats

notre matrice de prédiction soit adaptée aux photos que notre capteur prend. Après avoir mené une recherche sur les différentes sociétés, les capteurs utilisés par chacune le choix s'est porté sur le capteur IR de la société Planet, qui a possède une constellation de satellites appelés PlanetScope.

Une fois la prédiction réalisée à bord du satellite, le satellite ne renvoie que la donnée de position du plastique ce qui permet de faire exploser le nombre de données exploitables.

Nous venons d'établir notre stratégie d'embarquabilité. Nous nous concentrons maintenant sur sa mise en œuvre pratique à bord du satellite : sur quel hardware allons-nous implanter nos algorithmes de prédiction ? Comment intégrer la mission de détection du plastique dans le CubeSat sans compromettre son autonomie énergétique ?

Dans un premier temps, notre équipe veut profiter du lancer du ballon en juin 2022 pour effectuer des tests. Après une étude des différentes cartes utilisables pour les algorithmes d'IA, l'architecture Tegra K1 que l'on trouve sur le kit JETSON NANO de NVIDIA semble être un bon choix. En effet le GPU nous permet d'effectuer de la parallélisation des tâches ce qui est très utile pour des algorithmes qui utilisent des réseaux de neurones, qui à terme seront utilisés par l'équipe.

D'un point de vue énergie ce kit ne consomme que 5 à 10W ce qui est correct au vu du bilan énergétique du CubeSat. De plus, il présente une puissance de calcul de 472Gflops ce qui est en adéquation avec les besoins de l'équipe IA.

Nous procémons à l'achat d'une carte de développement JETSON NANO afin de réaliser les premiers tests de consommation énergétique. A ce stade, nous avons mis en place tout l'environnement nécessaire à l'utilisation de la carte et nous avons déjà fait tourner quelques algorithmes de Computer Vision, notamment de tracking et de motion estimation (estimation de mouvement). Maintenant que nous sommes familiarisés avec son fonctionnement, nous allons lancer notre phase de tests.



FIGURE 2 – Carte de développement jetson nano avec algorithme de tracking et utilisation des cpu

La stratégie de tests est la suivante : faire tourner les différents types d'algorithmes que nous envisageons d'utiliser (cf Section 2.3) sur la JETSON NANO, afin d'obtenir le temps d'exécution de chacun pour une photo. Une fois ces informations obtenues, nous pourrons procéder à un premier classement de ces algorithmes par efficacité. Éventuellement certains d'entre eux pourraient être écartés car trop coûteux en énergie et donc impliquer de traiter trop peu de photos, ce qui limiterait l'utilité du service. Par la suite, nous

2. Résultats

devons évaluer quelle énergie doit être fournie par le satellite afin de traiter les photos prises par le capteur. A ce stade là, il va falloir trouver un équilibre entre les ressources en énergie disponibles et la stratégie de prises de photos. Il faudra nous baser sur le travail effectué par l'équipe en charge de l'énergie du CubeSat afin de dresser un bilan de puissance et en déduire le temps de fonctionnement autorisé pour la carte par jour. Nous définirons à partir de ces données une cadence de prise de photos et un nombre de photos prises par jour. Une donnée qu'il nous semble intéressant d'évaluer est le coût énergétique pour couvrir une surface de 100kmx100km, soit une dizaine de photos prises d'affilée par le satellite, ce qui correspondrait à notre potentielle stratégie de prise de photos à ce stade de notre réflexion. En effet, sachant que la mémoire RAM de la carte est de 2GB, nous pourrons stocker 10 photos environ avant de les traiter immédiatement après. Nous déclencherons la prise de photos au moment où nous saurons, grâce à la télémétrie du satellite, que nous nous trouvons au-dessus d'une zone cible. Sachant que la fauchée d'une photo prise par le capteur est de 24kmx8km, prendre 10 photos nous permettra de couvrir une zone d'environ 100kmx100km et de contourner le fait que certaines photos seront inexploitables.

2.2. Données

Cette partie présente les caractéristiques de l'ensemble des données qui ont été utilisées, et qui seront utilisées à l'avenir.

2.2.1. Sentinel-2

Pour la première partie de nos recherches, les images qui ont été utilisées sont issues de la mission spatiale européenne Sentinel-2A. Ces images présentent les deux avantages d'être disponibles en libre accès et sont le support de certaines recherches acutelles. Elles possèdent 13 bandes spectrales :

Bandes spectrales	Longueur d'onde (nm)	Résolution (m)
B01	442.7	60
B02 - Bleu	492.4	10
B03 - Vert	559.8	10
B04 - Rouge	664.6	10
B05	704.1	20
B06	740.5	20
B07	782.8	20
B08 - Proche IR	832.8	10
B8A	864.7	20
B09	945.1	60
B10	1373.5	60
B11	1613.7	20
B12	2202.4	20

TABLE 1 – Bandes spectrales du capteur de sentinel-2

Ces bandes spectrales sont suffisamment nombreuses et recouvrent suffisamment de domaines spectraux pour être utiles à la détermination des longueurs d'ondes permettant de détecter des cibles plastiques dans les océans.

Ces images ne sont cependant pas optimales pour la détection de plastique : leur résolution de 10 mètres maximum (un pixel représente une surface réelle de 10m x 10m) est faible et rendra impossible la détection de petites cibles ou de regroupement épars de déchets. D'après [3], un amas compact doit recouvrir au moins 30% de la surface pixel pour être détecté, soit une surface compacte de 5m x 6m.

2.2.2. Planet

Il est démontré en partie 4 que les bandes spectrales du capteur de Sentinel-2 les plus discriminantes pour la détection de plastique étaient les suivantes : B02, B03, B04, B08 (Respectivement bleu, vert, rouge et proche infra rouge). Le capteur multispectral embarqué sur le nanosatellite devra à minima posséder ces bandes spectrales. Les recherches menées dans la partie 1 ont abouties dans la sélection du capteur similaire à celui de la constellation Planetscope de l'entreprise Planet¹ :

Bandes spectrales	Longueur d'onde (nm)	Résolution (m)
Bleu	455 - 515	3
Vert	500 - 590	3
Rouge	590 - 670	3
Proche IR	780 - 860	3

TABLE 2 – Bandes spectrales du capteur de Planetscope

Ce capteur possède une résolution suffisamment faible et les bandes spectrales requises pour permettre la détection de déchets plastiques dans les océans. Nous avons obtenu un accès gratuit à ces images donc nous les utiliserons préférentiellement.

2.2.3. Crédit d'un dataset : Simplastic

Afin de pouvoir explorer toutes les techniques de machine learning, et notamment d'apprentissage supervisé, nous avons besoin d'avoir des données labellisées. Il existe très peu de jeux de données indiquant la position des déchets plastiques associés à des images satellites. Nous avons deux solutions pour créer ces jeux de données :

1. Croiser les informations qui existent sur internet (images et localisation des déchets).
2. Générer des données labellisées à partir des images que nous avons déjà récupérées (data augmentation), qui est la méthode que nous avons explorée avec les données Sentinel-2.

Cette méthode implique la simulation de la présence de plastique dans les océans : remplacer la valeur pixel de classe “eau” par la valeur d'un pixel de classe “plastique” (cf Section 2.3.1, Kmeans), à partir des images utilisées par [3]. Il existe cependant deux problèmes majeurs. Il est nécessaire de rester dans la même zone géographique que les données d'origine. Les composantes d'un pixel plastique dépendent de l'environnement de ce pixel, comme par exemple la couleur de l'eau. D'après la figure 3, la réflectivité de l'eau est très différente selon la zone observée. Les graphes ci-dessous présentent la réflectivité de l'eau en fonction de la distance du pixel observé à la côte. Cette réflectivité augmente fortement plus on s'éloigne de la côte. La position de nouveaux pixels plastique devra être semblable à celles des cibles posées par [3], et où la réflectivité est constante.

Pour ce dataset, il a été décidé de placer des pixels plastiques au maximum 5 pixels (soit 50 mètres) au large des côtes. Le label sera un tableau avec des 1 pour les pixels plastique, et des zéros partout ailleurs. Le dataset a donc été créé de la manière suivante :

1. Sélection de deux images issues de Sentinel-2 autour des lieux d'intérêts (PLP).
2. Segmentation de l'image avec un K-means (Terre et eau).
3. Recherche des littoraux.
4. Sélection des pixels eau à modifier selon une probabilité.
5. Ajout d'un bruit et modification du pixel considéré.
6. Crédit du label.

1. Résolution originale de 3.7 m et réajustée à 3 m

2. Résultats

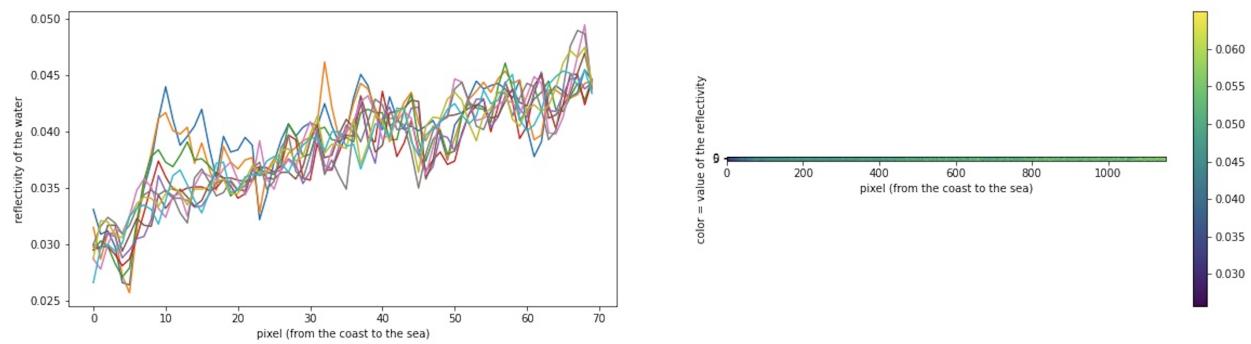


FIGURE 3 – Réflectivité de l'eau en fonction de sa distance à la côte

Il résulte environ 290 000 pixels dont 80 pixels plastique. Les résultats obtenus en partie 2.3 indiquent que le dataset ne permet pas d'améliorer les résultats de prédictions sur des images où la présence de plastique est vérifiée. Ces mauvais résultats viennent de la simplicité de sa création. Les pixels placés aléatoirement sont trop différents de la réalité et ne prennent suffisamment pas en compte leurs environnements pour pouvoir être utilisés sur des données réelles.

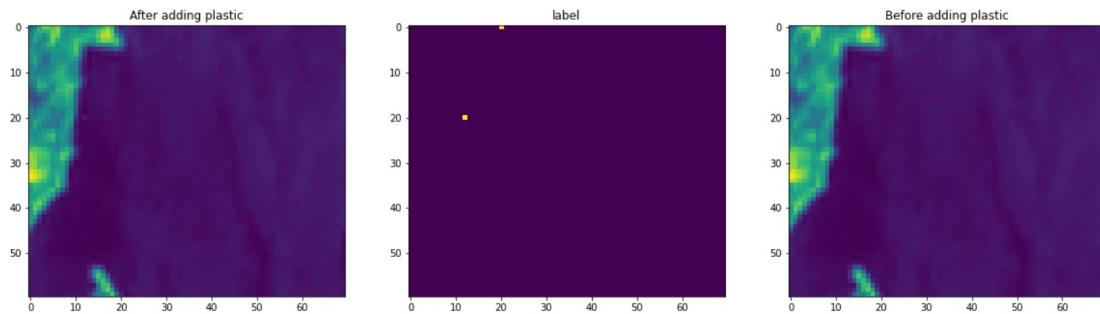


FIGURE 4 – Image et son label issus du dataset final

2.3. Algorithmes d'IA

Cette partie regroupe tous nos développements en intelligence artificielle pour la détection de plastique en mer. Dans un premier temps, nous étudions la signature spectrale du plastique, afin d'avoir plus de précisions sur les algorithmes que nous avons retenus.

Nous avons exploré à la fois les algorithmes d'apprentissage supervisé et non-supervisé. Les résultats sont présentés ci-dessous. Nous avons tout de suite écarté la possibilité d'utiliser les réseaux de neurones, en raison de la trop petite quantité de données labelisées.

2.3.1. K-means et spectral unmixing

1. Analyse des caractéristiques du plastique

a. Méthode

Avant de choisir les algorithmes adéquats à l'étude et afin de limiter l'étude aux bandes spectrales essentielles, il faut dans un premier temps étudier les propriétés discriminantes du plastique sur les données spatiales choisies. Pour ce faire, il a été choisi d'utiliser l'algorithme de clustering par la méthode des k-means appliquée dans un environnement contenant du plastique (4 pixels plastique entourés d'une trentaine de pixels eau), appliqués avec le paramètre $K=2$ (nombre de clusters). Il a été vérifié que le clustering classifie correctement les pixels plastique et eau sous le bon label. Les signatures spectrales de l'eau et du plastique correspondent aux centres des clusters calculés précédemment. Nous calculons ensuite l'erreur quadratique des courbes normalisées afin de mettre en évidence les discriminations comportementales (et non en valeur nécessairement, bien que le plastique réfléchisse plus la lumière que l'eau) du plastique et de l'eau.

b. Résultats et discussions

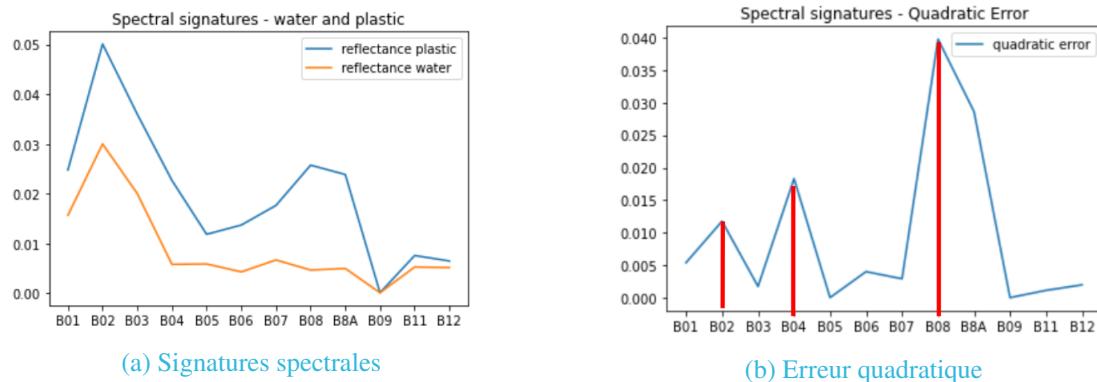


FIGURE 5 – Signatures spectrales extraites : eau et plastique

Les résultats sont présentés en Figure 5. En général, la réflectivité du plastique est plus élevée que celle de l'eau selon la Figure 5(a). Mais la valeur de cette réflectivité peut varier avec le bruit, les nuages etc donc il faut surtout regarder les différences comportementales (et non en valeur). D'où l'erreur quadratique moyenne des courbes normalisées pour nous aider, sur la Figure 5(b). Les bandes discriminantes sont B02, B03, B04 et B08, qui correspondent aux domaines du visible et du proche infrarouge (RGB+NIR).

Cette méthode de clustering permet également d'effectuer une segmentation simple et efficace pour séparer la terre de la mer de l'océan. Cela est essentiel dans le cadre de nos recherches puisque les images utilisées comportent systématiquement un bout de terre qui constitue une barrière à la détection du plastique.

2. Spectral unmixing

a. Méthode

2. Résultats

Une fois les signatures des composantes d'intérêt extraites, à savoir les composantes eau et plastique, il s'agira de calculer l'abondance de chacune de ces composantes par la méthode de linear spectral unmixing. N'ayant les signatures de seulement 2 composantes (l'image contenant beaucoup plus de composantes telles que la terre), nous choisissons d'utiliser une formule partielle de spectral unmixing, appelée Mixture Tuned Matched Filtering (MTMF) [8]. L'abondance de chaque composante pour chaque pixel est estimée selon la formule suivante :

$$\hat{\phi}_{MTMF} = ((\vec{e}_z^T * \mathbf{R}^{-1} \vec{e}_z)^{-1} \mathbf{R}^{-1} \vec{e}_z)^T x \quad (1)$$

où \vec{e}_z représente le vecteur de la composante dont on veut mesurer l'abondance, x le pixel étudié, et \mathbf{R} la matrice de corrélation de l'image considérée.

Cette abondance étant partielle, elle ne somme pas à 1 sur un même pixel. Mais elle permet d'indiquer la présence ou non de plastique par rapport à une présence d'eau.

b. Résultats et discussions

Les pixels détectés sont entourés sur la Figure 6. Une des faiblesses de la formule est le fait qu'elle ne prenne pas en compte les 2 composantes à la fois pour pouvoir ajuster le calcul de l'abondance. Il faudrait soit utiliser une formule couplant ces deux composantes à la fois, soit calculer plus de composantes et utiliser une formule de calcul d'abondance complète (non partielle), de sorte à ce que la somme des abondances pour chaque élément vaille 1.

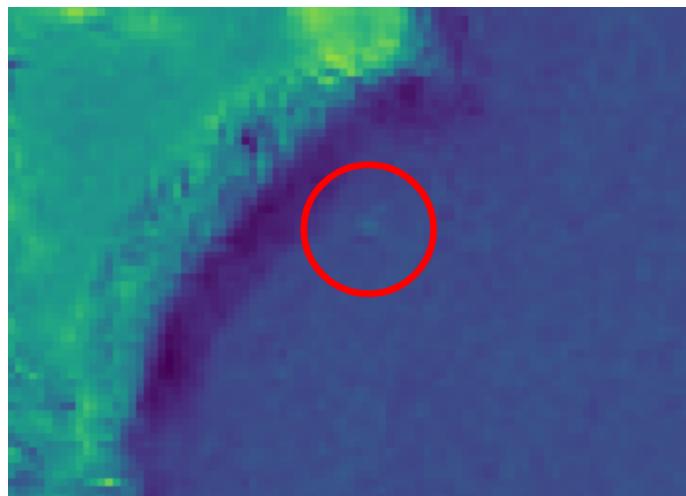


FIGURE 6 – Résultats obtenus après un premier spectral unmixing

2.3.2. KNN et Naive Bayes

1. Algorithme KNN

a. Méthode

Nous avons dans un premier temps utilisé la technique de classification KNN. Pour effectuer une prédiction, l'algorithme KNN repose sur le jeu de données en entier. Il s'agit donc d'une technique d'apprentissage supervisé. L'algorithme KNN suppose que des individus similaires existent à proximité dans un espace défini à partir de caractéristiques données (plus proches voisins). La notion de proximité est formalisée par un calcul de distance. La distance la plus couramment utilisée est la distance Euclidienne (il en existe d'autres : distance Manhattan, distance Hamming, ...). Ainsi pour un pixel donné, du dataset de test, que l'on souhaite prédire, l'algorithme va chercher les K instances les plus proches en se basant sur la norme euclidienne et les bandes spectrales. Ensuite, l'algorithme se basera sur la classe majoritaire des voisins (plastique ou non plastique) pour déterminer la classe du pixel que l'on souhaite prédire.

Nous avons utilisé un dataset de 6 images (cf Marine Litter), on a créé un tableau de pixels de taille 94428 que l'on a séparé en training et testing set. On a aussi utilisé le dataset généré par Data-augmentation

2. Résultats

(cf 2.2.3) avec 281400 données. Pour cette technique, il s'agira de faire varier K pour trouver le modèle optimal.

b. Résultats

Les résultats se sont avérés peu concluants et ce pour les deux datasets. Même si on obtient une bonne précision lors de la classification (proche de 1) d'autres indicateurs tels que le F1 score ou le rappel sont assez mauvais (proche de 0). Concrètement, quelle que soit la valeur de K choisie, aucun des pixels de plastique du subset de Test n'a été classifié comme plastique par le modèle. Même si on obtient de meilleurs résultats sur un subset de test du dataset généré, la généralisation sur nos images ne fonctionne pas. L'une de nos hypothèses est qu'il y aurait trop d'over-fitting avec les données générées.

Finalement, on peut aisément conclure que cette technique ne fonctionne pas dans le cadre de notre projet. La quantité de données insuffisante et le fait que la classe plastique soit largement sous-représentée ne conviennent pas à un algorithme comme KNN qui reposent autant sur le dataset.

2. Algorithme Naïve Bayes

a. Méthode

On s'est aussi intéressé au classifieur Naïve Bayes qui s'appuie sur le théorème de Bayes. Comme présenté dans l'état de l'art, l'objectif est d'utiliser les données labellisées pour associer les pixels d'une image à des catégories à partir des signatures spectrales et de probabilités conditionnelles calculées empiriquement. C'est une technique dit d'apprentissage supervisé puisqu'elle requiert des données labellisées. L'avantage est qu'il s'agit d'un algorithme qui demande peu de données pour être efficace en comparaison à l'algorithme de KNN par exemple. Les mêmes données que précédemment ont été utilisées.

b. Résultats

Encore une fois, comme le montre la matrice de corrélation, les résultats ne sont pas bons. Aucun des pixels de plastique n'a été classé comme tel. Il semble y avoir le même problème que pour l'algorithme précédent. Il y a trop peu de données pour pouvoir classer correctement les pixels.

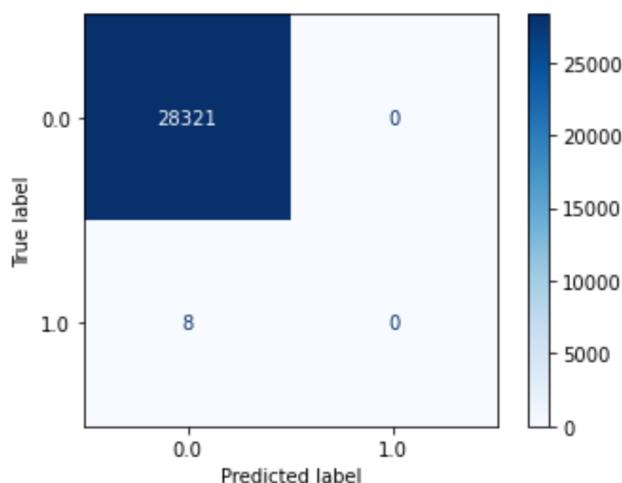


FIGURE 7 – Matrice de Corrélation pour l'algorithme Naïve Bayes

2.3.3. Tests d'hypothèses

1. Première approche : Détection d'anomalies et Tests Statistiques

a. Motivations

Nous avons pu observer que le problème que nous souhaitons résoudre présente une grande disparité de représentation des classes (plastique vs non-plastique) : en effet, sur une image, la majorité des pixels ne sont pas des pixels représentant du plastique, et seulement très peu appartiennent effectivement à la classe "plastique". Cette différence explique en partie les mauvaises performances des algorithmes classiques. On souhaite donc ici réaliser une **détection d'anomalie**, où le plastique va être traité comme une anomalie par rapport au fond marin. L'avantage de ce type d'algorithme est qu'il fonctionne bien lorsqu'une classe est largement sous-représentée, ce qui est notre cas.

b. Méthodes

Pour chaque bande spectrale, nous allons nous focaliser sur la distribution statistique des pixels de l'image : le type de distribution et les paramètres associés (moyenne, variance).

L'idée ici est d'entraîner un classifieur capable de détecter ou non la présence de plastique sur chaque pixel de l'image. Pour ce faire, on entraîne un classifieur sur une partie de l'image ne contenant (à priori) pas de plastique. Dans cette étape, l'entraînement consiste à extraire les caractéristiques de distribution de l'ensemble des ces pixels : leur variance et leur moyenne. On peut ensuite tracer l'histogramme de ces pixels pour tenter d'identifier une distribution dont la loi est connue, et y relier les 2 paramètres. Pour une loi gaussienne par exemple, de moyenne μ et d'écart type σ , la densité de probabilité est de la forme : $f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{1}{2}(\frac{x-\mu}{\sigma})^2}$. Cette hypothèse est bien évidemment à vérifier. Dans cette première partie introducitive sur les tests d'hypothèse, nous l'avons appliquée. Ensuite, pour une image donnée, on compare chaque pixel à la distribution déterminée précédemment. Grâce à un seuil qu'il faut choisir, on peut ainsi espérer déterminer si chaque pixel suit ou non cette distribution. Un pixel qui ne suit pas cette distribution sera alors classifié comme une anomalie.

c. Résultats et Discussion

D'abord nous effectuons un prétraitement des images :

- Importation d'une image, comportant 12 bandes spectrales. On la traite sous forme d'un tableau à 3 dimensions : Hauteur*Largeur*NbBandesSpectrales
- Suppression des pixels correspondants à la terre. Pour ce faire, on utilise un K-Means à 2 classes (Terre/Mer). On obtient le résultats de la figure 8 :



FIGURE 8 – Segmentation d'une image avec un Kmeans à 2 classes

En poussant cette segmentation plus loin, avec dans ce cas 8 classes, on obtient cependant les résultats de la figure 9.

On retrouve ici le problème soulevé à la fin de la partie 2.2.3 : on observe une différence entre les zones proches de la côte et les zones de haute mer. Avec cette méthode, il faudrait donc effectuer la détection sur ces deux zones différentes, ce qui pose un problème au niveau de l'automatisation de l'algorithme.

2. Résultats

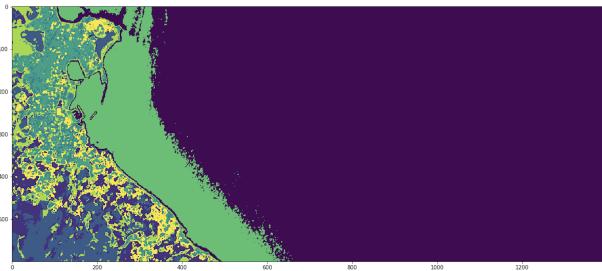


FIGURE 9 – Segmentation d'une image avec un Kmeans à 8 classes

i. Une bande spectrale

Pour une seule bande spectrale donnée, on extrait d'abord les caractéristiques statistiques d'une sélection de pixels non plastiques. On fait l'hypothèse d'une distribution gaussienne (vérifiée en partie par le calcul de l'histogramme des pixels de l'image, même si une transformation des données semble souhaitable). Ensuite, pour chaque pixel de l'image, on teste grâce à un seuil l'appartenance à cette distribution. On obtient les résultats présentés à la figure 10, avec un seuil fixé à 0, 1.

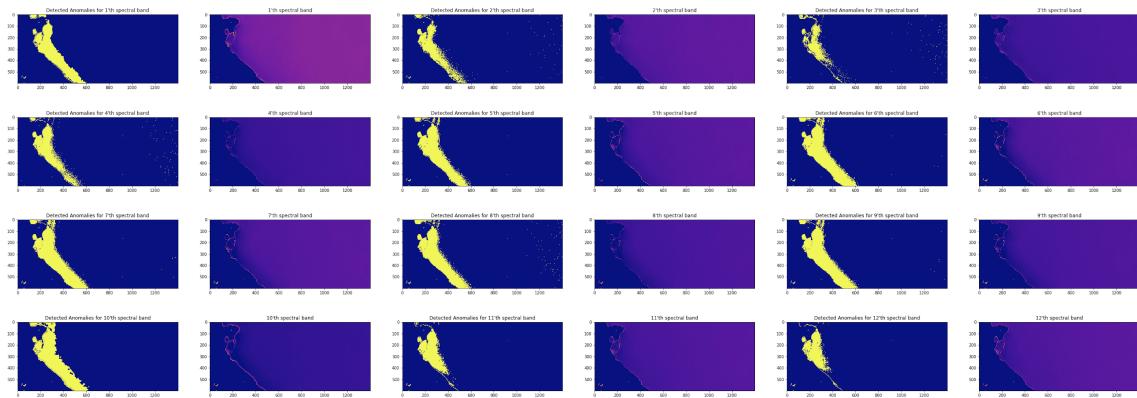


FIGURE 10 – Anomalies pour chaque bande spectrale

Deux problèmes évidents apparaissent alors : le choix du seuil de détection, et les grandes différences que l'on observe pour chaque bande spectrale. De même, on retrouve le problème évoqué ci-dessus : l'apprentissage des caractéristiques statistiques ayant été fait en zone "haute mer", en haut à droite de l'image, tous les pixels appartenant à la zone proche de la côte sont classifiés comme des anomalies.

ii. Plusieurs bandes spectrales

Pour plusieurs bandes spectrales, la méthode reste similaire : on extrait les caractéristiques statistiques sur chaque bande spectrale, et on fait toujours l'hypothèse d'une distribution gaussienne sur chacune de ces bandes. La fonction de prédiction apprise est cette fois-ci le produit des distributions obtenues pour chaque bande spectrale. Cela suppose donc l'indépendance des différentes bandes spectrales entre elles, ce qui paraît peu réaliste. Pour effectuer une prédiction, on calcule la valeur d'un pixel multispectral par la fonction de prédiction, et on compare le résultat à un seuil. On obtient donc bien une seule valeur de prédiction, quel que soit le nombre de bandes spectrales utilisées. Un exemple de résultat est donné à la figure 11, avec un seuil de détection fixé à 0, 01.

Si on souhaite ne pas faire l'hypothèse d'indépendance entre les bandes spectrales, on peut construire la fonction de prédiction en utilisant une loi de plusieurs variables (en fait la loi d'un vecteur que l'on suppose ici gaussien). Le calcul de cette loi nécessite cependant le calcul de la matrice de covariance Σ du jeu d'entraînement.

Précisions ici les calculs : Soit un jeu d'entraînement de m pixels $\{x^1, x^2, \dots, x^m\}$, où chaque pixel x possède

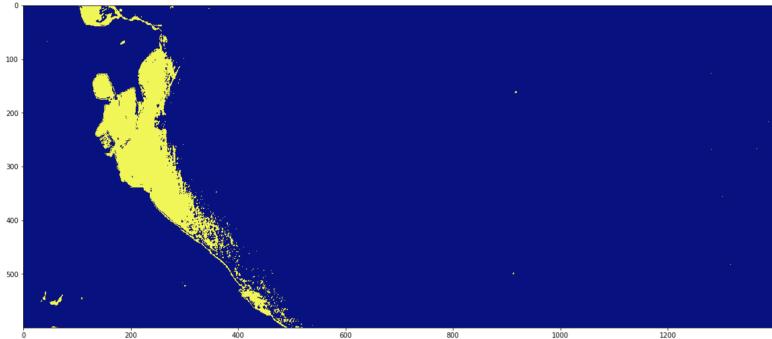


FIGURE 11 – Anomalies sur plusieurs bandes spectrales

n composantes spectrales ($x \in \mathbb{R}^n$). Alors le vecteur des moyennes et la matrice de covariance sont

$$\vec{\mu} = \frac{1}{m} \sum_{i=1}^m x^{(i)} \quad \text{et} \quad \Sigma = \frac{1}{m} \sum_{i=1}^m (x^{(i)} - \vec{\mu})(x^{(i)} - \vec{\mu})^T$$

La fonction de prédiction (i.e. la loi d'un pixel comme vecteur gaussien) est alors :

$$p(x, \vec{\mu}, \Sigma) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} e^{-\frac{1}{2}(x-\vec{\mu})^T \Sigma^{-1} (x-\vec{\mu})}$$

Pour une zone suffisamment grande de $200 \times 800 = 160000$ pixels sur 12 bandes spectrales, il faut calculer un produit matriciel d'une matrice de dimension 160000×12 , soit 1920000 éléments, ce qui demande malheureusement trop de mémoire pour nos propres machines.

On peut tirer de ces apprentissages que ce type de méthode statistique est très prometteur.

2. Modélisation du problème par la détection d'un signal constant connu dans un bruit gaussien connu

a. Méthode

Après la partie introductive sur l'approche des tests statistiques, le choix a été fait de proposer une méthode plus rigoureuse mathématiquement parlant. Il a été choisi dans un premier temps de se baser sur des hypothèses simples en considérant le plastique comme étant un signal constant A noyé dans un bruit w . Ces paramètres sont d'abord considérés comme étant connus. Afin de les déterminer, il faut étudier les distributions des pixels eau et la valeur moyenne des pixels plastique pour fixer w et A . Pour cela, nous allons considérer une image avec du plastique labellisé. Nous considérerons également la signature spectrale du plastique extraite dans la partie 2.3.1 Les résultats obtenus pourront être trouvés sur les Figures 12 et 13.

Un algorithme python simple permet de choisir la loi qui décrit le mieux les distributions correspondantes aux pixels eau pour chaque bande spectrale. On remarque qu'en général la courbe a une tendance de lognorm. On pourra songer à effectuer une transformation pour normaliser le bruit. Par soucis de simplicité, nous commençons par nous focaliser sur la B04 qui possède une distribution selon une loi Gaussienne.

Avant d'effectuer les tests statistiques, nous allons centrer et réduire notre image sur laquelle nous avons enlevé la terre grâce au kmeans présenté en 2.3.1.

Nous allons implémenter un détecteur nous permettant de tester les deux hypothèses suivantes, pour n variant de 1 à N :

$$\begin{cases} x(n) = w(n) & \text{si } H_0 \\ x(n) = w(n) + A & \text{si } H_1 \end{cases}$$

où $x(n)$ désigne le pixel observé n , $w(n)$ le bruit gaussien de moyenne et variance connue, et A le signal constant connu. Premièrement, nous déduisons l'expression de la statistique qui nous servira de détecteur, à partir du ratio de log-vraisemblance. Cette statistique vérifie :

2. Résultats

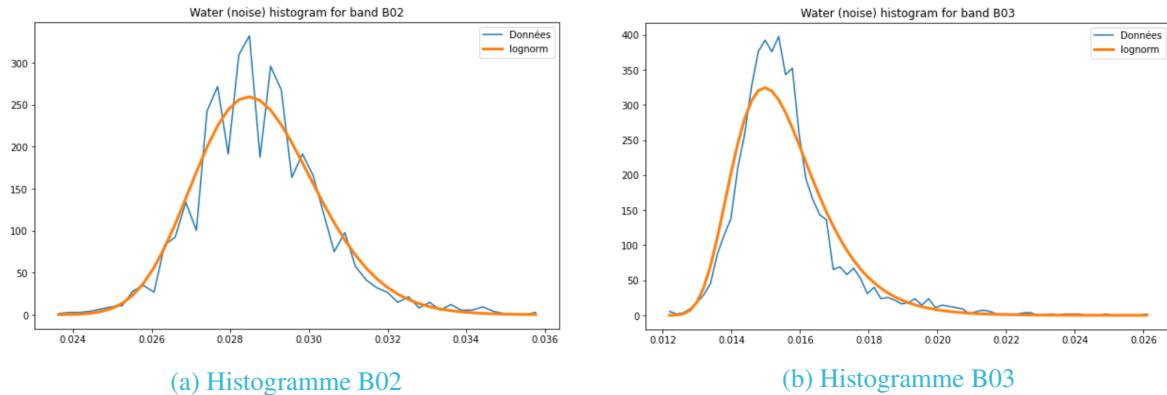


FIGURE 12 – Histogrammes partie 1

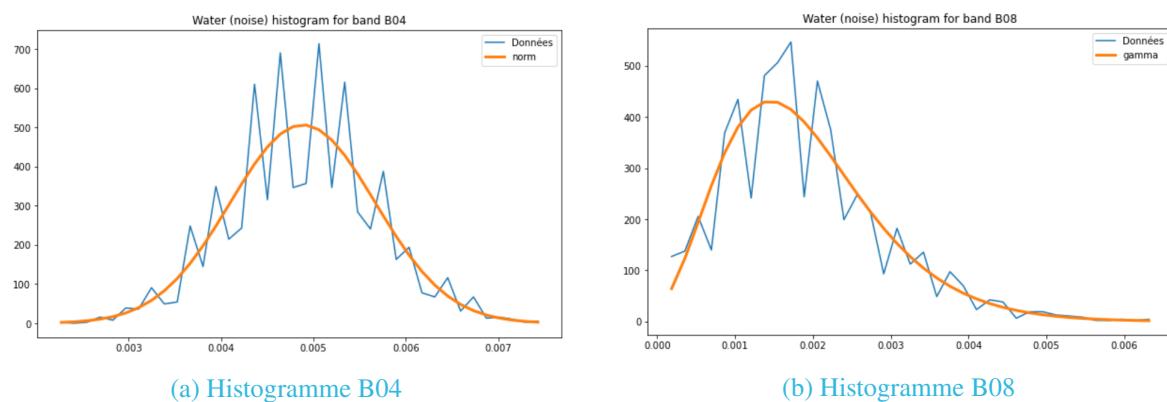


FIGURE 13 – Histogrammes partie 2

$$T(x) = \frac{1}{N} \sum_{n=0}^{N-1} x(n) > \gamma = \frac{\sigma^2}{NA} \ln(\lambda) + \frac{A}{2} \quad (2)$$

Lorsque la statistique sera supérieure au seuil γ , on rejettéra l'hypothèse nulle H_0 et on considérera qu'il y a présence de plastique dans le bruit, ici l'eau.

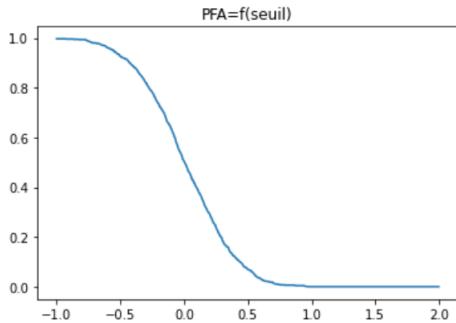
Le choix du seuil se fait par rapport à la probabilité de fausse alarme (PFA) ou la probabilité de détection correcte (PD), que l'on veut respectivement minimiser et maximiser. Ne pouvant pas avoir des résultats optimaux pour la PFA et la PD à la fois, nous devons choisir le paramètre à optimiser. Nous allons affiner ces seuils à tâton, mais nous commenceront par nous fixer une $PD > 80\%$ et une $PFA < 10\%$.

Pour fixer ce seuil, nous allons simuler 1000 fois, via la méthode de Monte Carlo, nos hypothèses H_0 et H_1 de manière indépendante et allons implémenter notre détecteur. Ensuite, pour différentes valeurs de seuil, nous allons calculer les PFA et PD, qui correspondent aux nombres de fois où $T(x) > \gamma$ pour H_0 et H_1 respectivement.

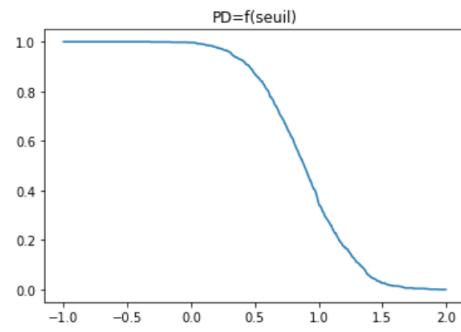
Nous allons ensuite tracer PFA et PD en fonction de γ , ainsi que la courbe ROC, qui revient à tracer PD en fonction de PFA. Sur la courbe de PFA, nous allons choisir le seuil γ en abscisses qui correspond au PFA désiré. Nous pourrons vérifier sur la courbe ROC que cela nous donne tout de même d'assez bons résultats de détection PD.

Afin de vérifier la cohérence entre le modèle théorique et les résultats expérimentaux, nous allons vérifier la distribution suivie par la statistique $T(x)$ suite à la simulation par Monte Carlo, en traçant les histogrammes nécessaires. Celle-ci doit suivre les lois suivantes :

2. Résultats



(a) Courbe PFA image 0



(b) Courbe PD image 0

FIGURE 14 – Courbes PFA et PD, image 0

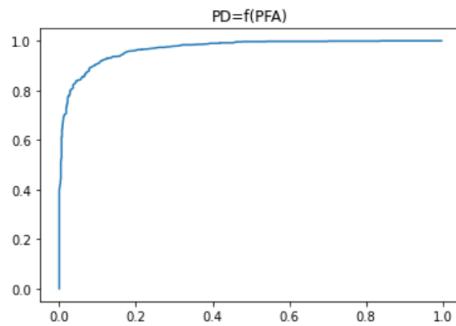


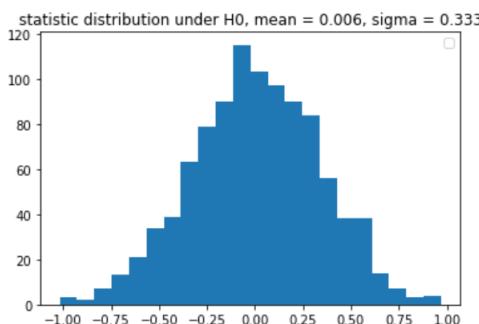
FIGURE 15 – Courbe ROC image 0

$$\begin{cases} T(x) \approx N(0, \frac{\sigma^2}{N}) & \text{si } H_0 \\ T(x) \approx N(A, \frac{\sigma^2}{N}) & \text{si } H_1 \end{cases}$$

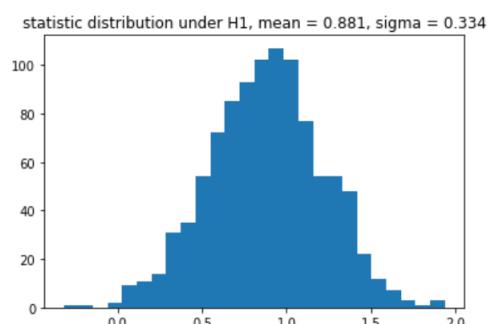
Une fois le seuil fixé et l’adéquation de la théorie avec l’expérimental vérifiée, nous appliquerons, sur un kernel carré de côté \sqrt{N} , notre statistique sur l’image, puis nous noterons les endroits où l’anomalie plastique est détectée, c’est-à-dire lorsque le seuil est dépassé. Nous choisissons $N = 9$ afin d’être plus précis sur la détection, tout en ayant plus de points pour calculer la statistique sans noyer le signal A .

b. Résultats et discussions

Le test est d’abord effectué sur l’image 0. Les courbes ROC (Figure 15), PFA et PD (Figure 14) indiquent un choix de seuil de $\gamma = 0.5$ pour avoir une bonne détection tout en minimisant la probabilité de fausse



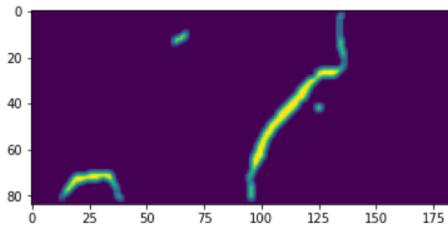
(a) Histogramme statistique H_0 , image 0



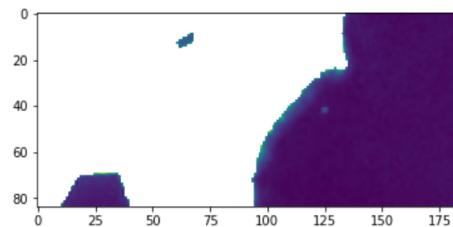
(b) Histogramme statistique H_1 , image 0

FIGURE 16 – Histogrammes statistiques, image 0

2. Résultats

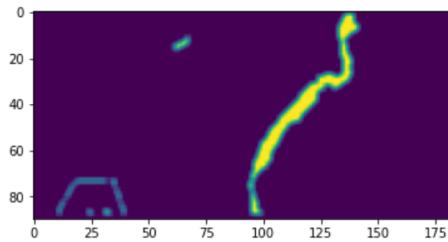


(a) Résultats de détection sur image 0

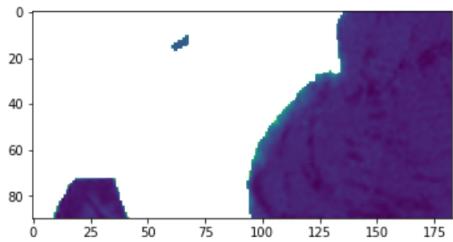


(b) Label image 0

FIGURE 17 – Résultats image 0



(a) Résultats de détection sur image 1



(b) Label image 1

FIGURE 18 – Résultats image 1

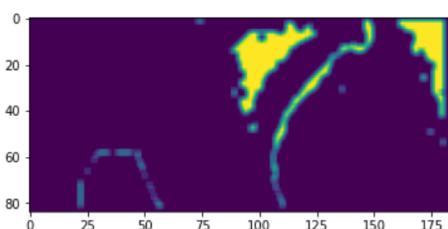
détection. Les statistiques suivent bien les distributions demandées dans la partie théorique d'après les histogrammes de la Figure 16. Le détecteur est donc bien implémenté.

Les résultats obtenus (voir Figure 17) sont très bons comparés au label (la cible de plastique est visible aux coordonnées (40,125) environ). Le sable est détecté mais cela semble logique vis-à-vis du fait qu'il reflète plus que l'eau. Cela ne nous dérangerai pas puisque l'objectif final est la détection des plastiques dans les océans.

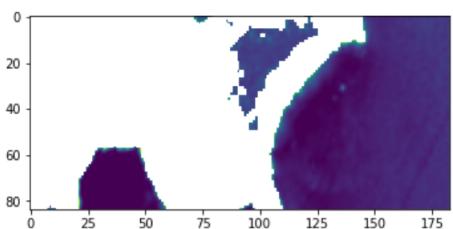
Testons les limites de l'algorithme en les appliquant sur les autres images que nous avons. Les Figures 18 et 19 montrent deux résultats intéressants à exploiter.

La Figure 19 montre qu'après avoir centré et réduit l'image et en conservant le même seuil γ que précédemment, la cible de plastique aux coordonnées (30,135) est bien détectée. Cependant, d'autres éléments dans l'océan sont aussi détectés. Cela est logique au regard de la Figure 20(b), où l'on voit que la valeur du pixel plastique est confondue avec la valeur des pixels eau. Il est ainsi difficile de les discriminer au milieu du bruit.

La Figure 18 n'a donné lieu à aucune détection du plastique avec le seuil fixé précédemment, bien que des cibles, moins visibles à l'oeil nu, soient présentes autour du point (40, 125). On a comparé les valeurs présentes sur l'histogramme de la Figure 20(a) à celles pour l'image 0 qui a servi à fixer le seuil, et on s'est rendus compte que la valeur des pixels plastique est bien inférieure dans ce cas (0.2 contre 0.8 sur l'image



(a) Résultats de détection sur image 5



(b) Label image 5

FIGURE 19 – Résultats image 5

2. Résultats

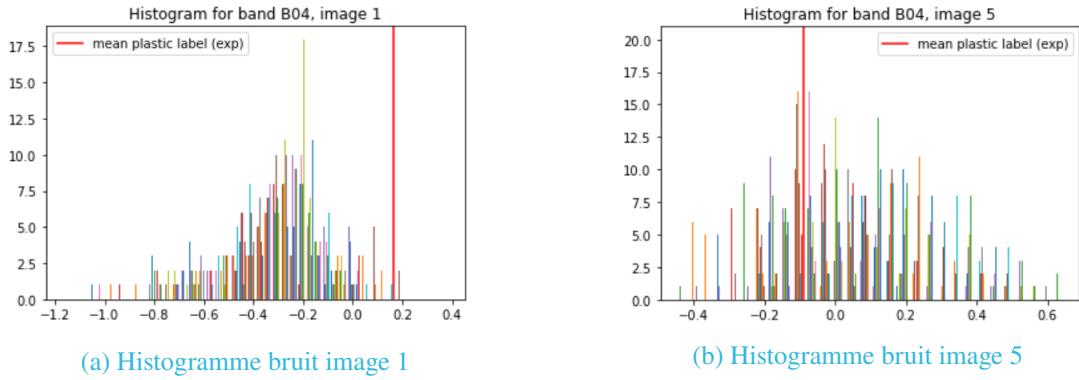


FIGURE 20 – Histogramme de l'eau comparé à la valeur des moyenne des pixels plastique dans ces images

0).

Cela a mis en évidences 2 problèmes majeurs avec cette méthode, ce qui rend compliqué sa généralisation. Premièrement, les réflectivités du plastique et de l'eau varient beaucoup d'une image à l'autre, rendant difficile le choix d'un seuil et également la discrimination. Par ailleurs, malgré le fait qu'on ait centré et réduit les images, on n'obtient toujours pas la même distribution du bruit. Il faut trouver une stratégie robuste afin d'homogénéiser le bruit et pouvoir généraliser. Un test que nous souhaitions faire est la détection d'une cible en pleine mer (non pas près d'un littoral). Cependant, nous n'avons pas de telles données à notre disposition.

Ainsi, au vu de la variabilité des paramètres A et w d'une image à l'autre, il n'est plus possible de les considérer comme étant connus. Il paraît intéressant de procéder alors à une estimation de ces paramètres sur chaque image considérée.

2. Modélisation du problème par la détection d'un signal constant inconnu dans un bruit gaussien inconnu

a. Méthode

Le bruit n'étant pas blanc, il faut un moyen de caractériser sa moyenne peu importe l'image. Sur une image où la terre aurait été enlevée par segmentation, il paraît cohérent de considérer que la moyenne de l'image, composée à 99% au moins d'eau, correspond à la moyenne de l'eau, et a fortiori du bruit. En effet, la valeur de A est très faible et a donc un impact négligeable dans cette moyenne. Comme précédemment, nous allons centrer et réduire les images.

Il faut ensuite estimer A et sigma sous les hypothèses présentées dans la partie précédente. Nous allons les estimer au sens du maximum de log-vraisemblance. On a :

$$\ln(p(x, H_0)) = \frac{-N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma_0^2) - \frac{1}{2\sigma_0^2} \sum_{n=0}^{N-1} x(n)^2 \quad (3)$$

$$\ln(p(x, H_1)) = \frac{-N}{2} \ln(2\pi) - \frac{N}{2} \ln(\sigma_1^2) - \frac{1}{2\sigma_1^2} \sum_{n=0}^{N-1} (x(n) - A)^2 \quad (4)$$

En dérivant par rapport aux différents paramètres selon que l'on se trouve sous l'hypothèse H0 ou H1, on trouve les estimations suivantes :

$$\hat{A} = \frac{1}{N} \sum_{n=0}^{N-1} x(n) \quad (5)$$

$$\hat{\sigma}_0^2 = \frac{1}{N} \sum_{n=0}^{N-1} x(n)^2 \quad (6)$$

2. Résultats

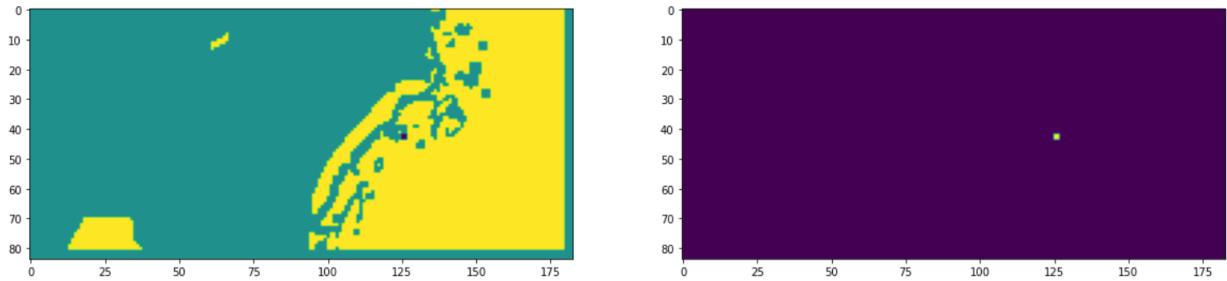


FIGURE 21 – Second test d’hypothèse appliqué à l’image image 0 VS label

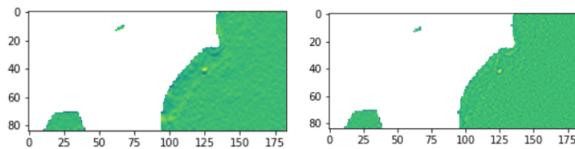


FIGURE 22 – Image 0 : Gradient à gauche, Laplacien à droite

$$\hat{\sigma}_1^2 = \frac{1}{N} \sum_{n=0}^{N-1} (x(n) - A)^2 \quad (7)$$

Ensuite, nous calculons l’expression de la statistique qui nous servira de détecteur. Pour ce faire, nous déterminons le ratio de log-vraisemblance et le comparons à un certain seuil. Après simplifications, nous obtenons :

$$T(x) = N \ln\left(\frac{\hat{\sigma}_0^2}{\hat{\sigma}_1^2}\right) \quad (8)$$

La suite suit la même méthode que celle présentée en 2.3.3 partie 2.a. Si le bruit est centré, notre statistique doit suivre la distribution :

$$\begin{cases} T(x) \approx \chi_1^2 & \text{si } H_0 \\ T(x) \approx \chi_1^2(\lambda) & \text{si } H_1 \end{cases}$$

Avec $\lambda = \frac{NA^2}{\sigma_0^2}$. Nous essaierons de nous positionner dans les hypothèses adéquates pour la suite.

b. Résultats et discussions

La figure 21 montre le résultat de cette méthode à gauche, avec le label représenté par un point bleu. A droite on retrouve ce même label. On remarque que toute l’eau est détectée comme étant du plastique. Soit notre implémentation est erronée, soit cette méthode ou les hypothèses avancées ne sont pas adaptées à notre problématique. Nous n’avons pas réussi à trouver l’erreur.

3. Test d’hypothèse simple pour la détection d’objets flottants

a. Méthode

Nous avons essayé d’appliquer la version simple de notre test d’hypothèse sur le gradient et le Laplacien des images. La figure 22 montre que ces transformations font clairement ressortir un relief à l’endroit où est le plastique. Il est donc cohérent d’y appliquer un test d’hypothèse. Le fait de prendre les dérivées première et seconde des images nous fait perdre l’information quand à la signature spectrale du plastique. On ne peut donc plus parler de détection de plastique mais de détection d’objets flottants.

b. Résultats sur les données Sentinel 2

2. Résultats

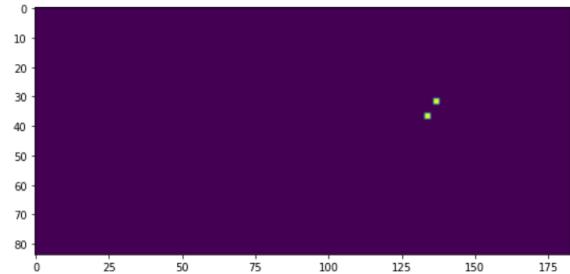
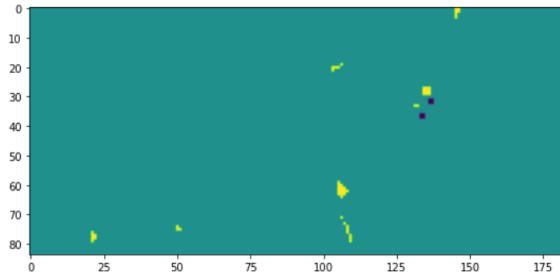


FIGURE 23 – Image 5 : Résultats test d’hypothèse sur le gradient

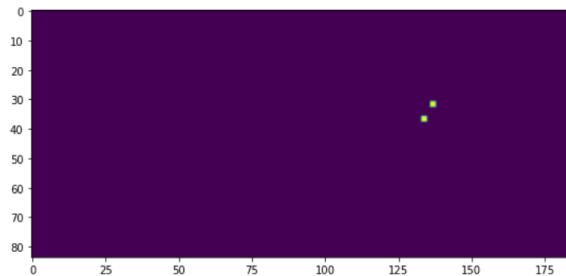
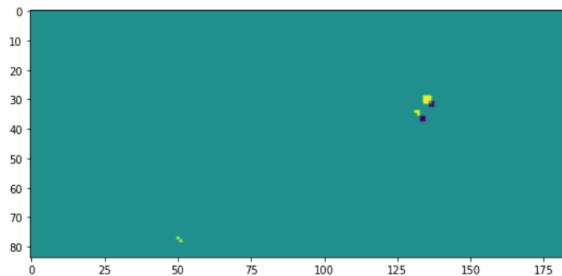


FIGURE 24 – Image 5 : Résultats test d’hypothèse sur le laplacien

Cette méthode, que ce soit sur le gradient ou le Laplacien, a permis de détecter à chaque fois le plastique. Il reste cependant quelques faux positifs, mais leur proportion est très négligeable et peut être réduite en choisissant un meilleur seuillage. Nous avons en général un score de Jaccard de 4%, score anormalement faible du fait d’un soucis de labellisation (les labels sont légèrement décalés par rapport à la position réelle du plastique).

Nous présentons ici seulement les résultats sur la dernière image de notre dataset, sur laquelle nous n’avons jamais réussi à obtenir des résultats concluants.

Les figures 23 et 24 montrent que les 2 cibles de plastique ont été très clairement et précisément détectées. Il reste quelques faux positifs sur l’image du gradient notamment, mais ceux-ci sont négligeables.

Cet algorithme est donc très prometteur en termes de robustesse pour la détection d’objets flottants et présente de nombreux avantages, notamment en termes de complexité puisque son temps d’exécution est très faible : seules 6 secondes sont nécessaires pour traiter toutes les bandes spectrales d’une seule image. Il pourra être utilisé notamment dans l’identification de régions d’intérêt, sur lesquelles nous pourront par la suite confirmer ou informer la présence de plastique grâce à un algorithme plus lourd.

c. Résultats sur une image Planet

Nous avons testé notre algorithme sur une image Planet, sans changer aucun paramètre. Les résultats sont présentés en figure 25, avec à gauche le résultat de l’algorithme appliqué au gradient et à droite appliqué au Laplacien. On remarque que les plastiques sont bien détectés (le label a été ajouté à la prédiction pour bien localiser le plastique, donc la visibilité de la prédiction est altérée). Cependant, on a beaucoup de faux positifs sur l’image avec le gradient. Il nous faudra donc adapter nos seuils pour avoir de meilleurs résultats. Nous avons tout de même obtenu un jaccard score de 22%.

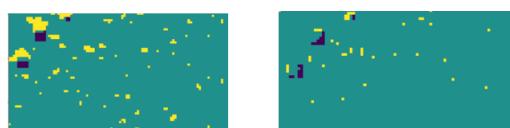


FIGURE 25 – Image 5 : Résultats test d’hypothèse sur une image Planet

2.3.4. Théorie des graphes - spectral clustering

Cette méthode d'apprentissage non supervisé, appelée spectral clustering, utilise la théorie des graphes pour segmenter l'image en différentes classes.

a. Quelques informations sur la théorie des graphes²

Un graphe mathématique est une structure composée d'individus et dotée d'une distance à partir de laquelle des liens sont construits entre ces individus. Soit $G = (V, E)$ un graphe où V est l'ensemble des individus, et E l'ensemble des liens entre ces individus. Soit N le nombre d'individus.

- Un chemin dans un graphe G est une suite d'individus permettant de relier deux individus.
- Un composant connecté d'un graphe G est un groupe d'individus pour lequel il existe un chemin entre tous les individus de ce groupe.
- La matrice d'adjacence A est la matrice de taille $N \times N$ avec des 1 lorsqu'il existe un lien entre les individus i et j , et 0 partout ailleurs :

$$A_{ij} = \begin{cases} 1 & \text{si } \{i, j\} \in E \\ 0 & \text{sinon.} \end{cases}$$

- Le degré d'un individus 'deg' est son nombre de voisins, c'est-à-dire le nombre d'individus avec lesquels il partage un lien. La matrice des degrés D est la matrice diagonale de taille $N \times N$ telle que :

$$D_{ij} = \begin{cases} \deg(i) & \text{si } i = j \\ 0 & \text{sinon.} \end{cases}$$

- On appelle la matrice de Laplace du graphe G la matrice L telle que :

$$L = D - A$$

Le spectre de L possède une propriété intéressante pour la classification de données :

Si un graphe G possède K composants, alors sa matrice de Laplace L possède K vecteurs propres associés à la valeur propre 0 (0 est de multiplicité K). Un graphe possède toujours au moins un composant, donc 0 sera toujours valeur propre (et sera la plus petite valeur propre).

b. Méthode

Soit N le nombre de pixels d'une image. Les N pixels de l'image représenteront l'ensemble des individus à partir desquels nous voulons créer un graphe. Le spectral clustering se sépare en X étapes :

1. Une matrice de similarité de taille $N \times N$ est d'abord créée telle que le coefficient i,j est la distance euclidienne entre le pixel i et le pixel j .
2. Une matrice d'adjacence est ensuite créée grâce à un seuil. Il existera un lien entre deux pixels i et j (ie le coefficient i,j de la matrice d'adjacence vaudra 1) si le coefficient i,j de la matrice de similarité est supérieur à ce seuil (le coefficient correspondant dans la matrice d'adjacence sera nul).
3. La matrice de Laplace et ses valeurs propres sont calculées. S'il n'y a qu'un seul composant, 0 est valeur propre de multiplicité 1. Si nous voulons segmenter l'image en K catégories (ie séparer les individus en K composants), nous devons nous intéresser à au vecteur propre associé à la K -ième plus petite valeur propre. Dans notre cas, $K = 2$.
4. Il est important que remarquer que les vecteurs propres sont de taille $N \times 1$, chaque élément correspondant à un individu. Un algorithme de clustering, ici un K-means, sera appliqué afin de séparer les individus deux catégories ce qui donnera la segmentation finale.

2. <https://towardsdatascience.com/unsupervised-machine-learning-spectral-clustering-algorithm-implemented-from-scratch-in-python-205c87271045>

2. Résultats

c. Pré-traitement

Afin d'améliorer les résultats du spectral clustering, un algorithme de K-means a été utilisé pour séparer l'eau de la terre. Les pixels "terre" ont ensuite été remplacés par la moyenne des pixels "eau" afin de minimiser la possibilité de placer les éléments de plastiques dans le même cluster que la terre. Une analyse de composant principal est aussi appliquée à l'image afin de réduire les variations de couleurs de l'eau et ainsi faire ressortir les pixels plastiques.

2. Résultats

d. Résultats et discussions

Après ce pré-traitement, le plastique est plutôt bien détecté. Prenons comme exemple l'image sentinel-2 représentée à la 26 :

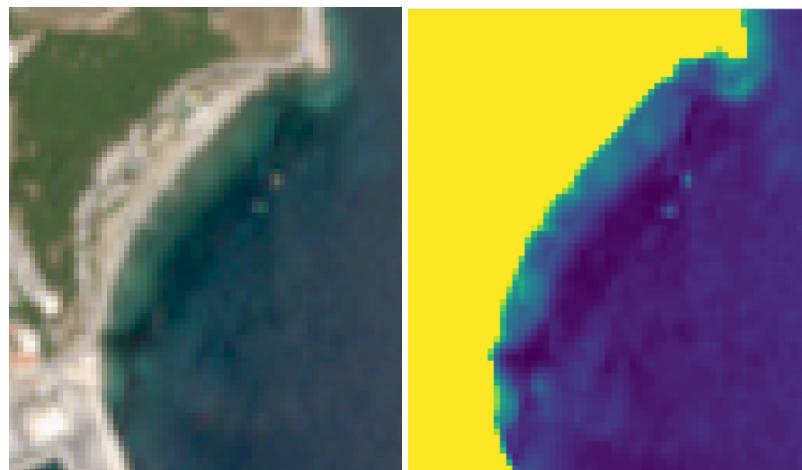


FIGURE 26 – Image dans le spectre visible (gauche) et bande spectrale B08 pré-traitée (droite) des cibles plastiques

Sur cette image, 2 cibles sont visibles, et on cherchera à segmenter cette image afin de les isoler du reste de l'environnement.



FIGURE 27 – Masques de segmentation avec, de gauche à droite, la création d'un graphe avec 50,100 et 150 plus proches voisins

La figure 27 présente les résultats obtenus après y avoir appliqué le pré-traitement ainsi que le spectral clustering, mais avec 3 différents seuils (déterminés avec la méthode "nearest neighbors"). A chaque fois, au moins une cible plastique est détectée : cela est très prometteur. Le clustering semble classer l'eau proche des côtes dans la même classe que le plastique. Lorsque l'on regarde l'image réelle ainsi que la bande spectrale B08, ces zones possèdent des reflectivités plus élevées que la moyenne, qui peuvent être confondues avec du plastique. Lorsque la profondeur de l'eau est très faible, le sable est visible à travers, et le pixel est à chaque fois classé dans la même classe que les cibles plastiques. Il est important de noter que la segmentation de l'image est très dépendante de la taille de celle ci. Plus l'image est grande, plus la variance entre les pixels sera grande et plus le clustering sera difficile. Cette méthode a eu des résultats similaires sur d'autres images de la même zone mais avec des cibles plastiques différentes. Le pré-traitement

2. Résultats

de l'image doit être développé afin de limiter la variance entre les pixels représentant de l'eau et mieux isoler le plastique de son environnement.

Cet algorithme a aussi été utilisé sur une image planet dans laquelle trois cibles plastiques sont présentes. Contrairement aux images sentinel 2, il a été possible d'avoir une image uniquement composée d'eau et des cibles plastiques :

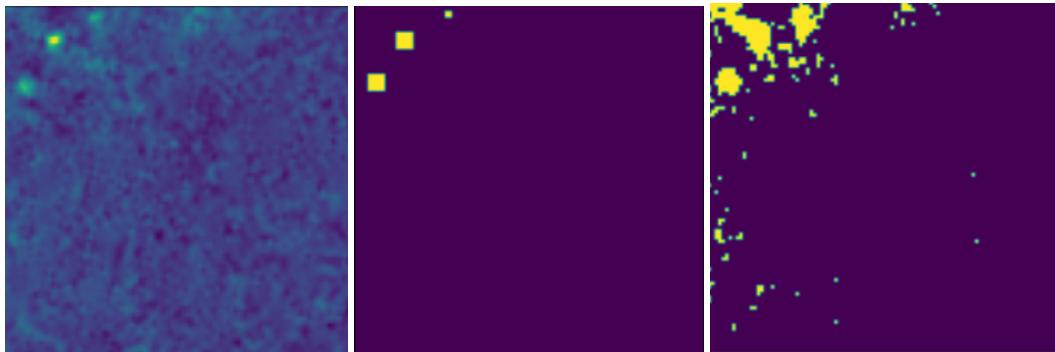


FIGURE 28 – Image Planet des cibles plastique, son label et la prédition du spectral clustering.

Pour situer cette image par rapport à l'image Sentinel 2, la côte se situe en haut à gauche des cibles plastiques. Ainsi, dans le coin en haut à gauche, la profondeur de l'eau est faible.

Les résultats obtenus sont bons. Le coefficient de Jaccard obtenu est de 22% : les cibles plastiques sont retrouvées, mais il y a beaucoup de bruit. La partie à gauche des cibles plastiques est aussi classée comme appartenant à la même classe que le plastique car la réflectivité est plus haute dans cet endroit, de la même manière que pour les images Sentinel 2.

L'apport de la meilleure résolution est très important car permet d'avoir d'avantages de pixels avec des réflectivités supérieures à la réflectivité de l'eau, ce qui améliore la qualité des résultats. Il reste cependant beaucoup de fausses alarmes, qui sont dues aux imperfections de la mer ou à la présence d'autres objets flottants.

3. Comparatif des méthodes utilisées

3.1. Critère d'évaluation de la qualité des prédictions

Ce projet se rapprochant beaucoup de la détection de petites cibles, il est nécessaire de choisir un critère d'évaluation adapté : un critère plus classique comme la précision ne donnerait pas des résultats reflétant la détection de plastique car serait biaisé par le déséquilibre des classes. Le coefficient de Jaccard sera donc utilisé.

Soit E la surface prédictive recouverte par l'eau dans une image, et P la surface prédictive recouverte par le plastique. Soit ER et PR les surfaces réelles données par les labels. Alors Le coefficient de Jaccard pour le plastique est :

$$J = \frac{P \cap PR}{P \cup PR}$$

En prenant l'intersection des surfaces réelles et prédictives, le coefficient de Jaccard est un bon indicateur de la précision des prédictions.

3. Comparatif des méthodes utilisées

3.2. Tableau comparatif

Algos Critères	Spectral Unmixing	Tests d'hypothèses	Naive Bayes et kNN	Spectral Clustering
Coefficient de Jaccard	Sentinel 2 : 0%	Sentinel 2 : 4%, Planet : 22%	0%	Sentinel 2 : 4%, Planet : 23%
Commentaires	Mauvaise prédiction des pixels de plastique avec une grande proportion de faux positifs. La classe de l'eau et du plastique sont conjointes.	Très bonne détection du plastique sur le Laplacien, peu de faux positifs. Le jaccard score est faible à cause du décalage induit par le calcul de la dérivée de l'image et le décalage original entre les labels et les cibles. Par contre, on ne détecte que les objets flottants, on n'exploite plus la propriété du plastique.	Aucun pixel de plastique n'a pu être classé comme tel. Aucun faux positif. Très mauvais Jaccard score.	Le plastique est bien détecté mais de nombreux faux positifs. Le coefficient de Jaccard est faible à cause de ce bruit, qui est souvent causé par la présence de vagues ou à une segmentation approximative de la terre. Il n'est pas certain que seul le plastique soit détecté et non tous les objets flottants.
Généralisation	Aucune généralisation possible avec les données en notre possession.	Le plastique (objet flottant) est détecté sur toutes les images (hormis celle avec beaucoup de nuages) avec peu de faux positifs si on applique l'algorithme sur le Laplacien de l'image.	Etant donné la très faible proportion de plastique dans nos images, l'apprentissage supervisé n'a pas montré de résultat. Cela ne semble, pour le moment, pas pertinent.	Le plastique est détecté sur les images où il est possible de le voir facilement à l'oeil nu. Du traitement d'image est nécessaire afin de réduire le bruit et faire ressortir les objets flottants.
Temps d'exécution sur ordinateur	20s	6s	10s	35s
Temps d'exécution sur jetson				
Coût énergétique				

TABLE 3 – Comparatif des méthodes utilisées

Selon le tableau 3, il ressort que les tests d'hypothèses sont les plus performants et les moins coûteux, notamment lorsqu'ils sont appliqués aux Laplaciens des images considérées. Cependant, l'utilisation du Laplacien implique de ne plus exploiter les propriétés du plastique, donc nous ne mettons plus qu'en évidence la présence d'objets flottants sur l'eau. Il serait donc intéressant d'appliquer cet algorithme pour déterminer des régions d'intérêt, puis d'y appliquer d'autres algorithmes de classification pour déterminer ou non la présence effective du plastique.

Le spectral clustering est très prometteur, mais est également très coûteux. Il pourra donc être intéressant de l'appliquer sur les régions d'intérêt définies par les tests d'hypothèses. Enfin, une version plus robuste

3. Comparatif des méthodes utilisées

des tests d'hypothèses permettra aussi de calculer l'abondance de plastique.

Une fois un algorithme de détection de plastique robuste établi, il nous sera alors possible d'envisager l'utilisation d'algorithmes d'apprentissage supervisés. Il serait intéressant de considérer des algorithmes auto-supervisés pour essayer de pallier au manque de données. Cependant, suite à une réunion avec des chercheurs de l'ESA, nous avons appris qu'un dataset de débris flottant sera publié très prochainement. Il s'agira alors d'exploiter ces recherches pour contrôler l'efficacité de nos algorithmes non supervisés ou entraîner des algorithmes d'apprentissage supervisé pour la détection d'objets flottants.

En ce qui concerne les données, on remarque que les coefficients de Jaccard sont meilleurs sur les données Planet que sur les données Sentinel 2. Cela vient d'une part de l'augmentation de résolution, mais aussi d'un problème de labellisation que nous n'avons pas réussi à résoudre. En effet, les labels sont légèrement décalés par rapport à l'image d'origine. De plus, lorsque l'on calcule le gradient ou le Laplacien de l'image, cela induit également un décalage. Les résultats sont donc bien meilleurs que les scores donnés. Bien que les données Planet donnent de très bon résultats, on observe beaucoup de bruit sur ces images, ce qui interroge sur la robustesse de ces algorithmes sur des cibles de plus petite taille.

4. Conclusion

Ce projet était un véritable challenge, sur lequel nous partions avec beaucoup de handicaps : très peu de données, celles que nous avons étant artificielles, peu de travaux de recherche concluants sur le sujet ... Nous avons donc dû faire preuve d'ingéniosité et de courage pour explorer des pistes en dehors des sentiers battus.

Parmi les algorithmes explorés, le plus adapté à la détection embarquée de plastique dans les océans est le test d'hypothèse. En effet, en plus d'être très peu coûteux, il permet de détecter avec précision les cibles de plastique. Cependant, il ne permet pas de valider la nature de l'objet détecté et ne détecte donc que les débris flottants. Mais ses avantages lui permettront de mettre en évidence des régions d'intérêt sur lesquelles nous pourront par exemple y appliquer l'algorithme de spectral clustering pour confirmer ou infirmer la présence de plastique.

A travers nos différents essais, nous avons pu constater que les algorithmes d'apprentissage supervisé ne sont pas envisageables pour la détection de plastique dans l'immédiat. Les données étant trop disparates, la proportion de pixels plastique est bien trop faible pour pouvoir entraîner un quelconque algorithme. Cependant, lors de notre réunion avec des experts de l'ESA, ceux-ci nous ont fait part de la publication prochaine de leurs travaux de recherche sur la création d'une base de données de débris flottants. Cette base de données nous permettra d'explorer les méthodes d'apprentissage supervisé.

Ce projet fut extrêmement enrichissant et formateur, et nous tenons à remercier l'ensemble de l'équipe pédagogique nous ayant accompagnés dessus.

5. Lien vers les codes

Dossier GitHub : https://github.com/BasileR/plastic_detection_from_space

Références

- [1] Ogunola Olunyi Solomon et Thava Palanisami, *Microplastics in the Marine Environment : Current Status, Assessment Methodologies, Impacts and Solutions*
- [2] Lonneke Goddijn-Murphy et Juvenal Dufaur, *Proof of concept for a model of light reflectance of plastics floating on natural waters*
- [3] Konstantinos Topouzelis ,Apostolos Papakonstantinou , Shungudzemwoyo P.Garabac, *Detection of floating plastics from satellite and unmanned aerial systems (Plastic Litter Project 2018)*
- [4] Konstantinos Topouzelis, Dimitris Papageorgiou , Alexandros Karagaitanakis, Apostolos Papakonstantinou et Manuel Arias Ballesteros, *Remote Sensing of Sea Surface Artificial Floating Plastic Targets with Sentinel-2 and Unmanned Aerial Systems (Plastic Litter Project 2019)*
- [5] Inmaculada Dopido, Alberto Villa et Antonio Plaza, *Unsupervised Clustering and Spectral Unmixing for Feature Extraction Prior to Supervised Classification of Hyperspectral Images*
- [6] N.Maximenko et all., *Toward the integrated marine debris observing systems*
- [7] Kyriacos Themistocleous, Christiana Papoutsas, Silas Michaelides et Diofantos Hadjimitsis, *Investigating Detection of Floating Plastic Litter from Space Using Sentinel-2 Imagery*
- [8] Shungudzemwoyo P. Garaba et Heidi M. Dierssen, *Hyperspectral ultraviolet to shortwave infrared characteristics of marine-harvested, washed-ashore and virgin plastics*

OUR WORLDWIDE PARTNERS UNIVERSITIES - DOUBLE DEGREE AGREEMENTS



3 CAMPUS, 1 SITE



IMT Atlantique Bretagne-Pays de la Loire – <http://www.imt-atlantique.fr/>

Campus de Brest

Technopôle Brest-Iroise
CS 83818
29238 Brest Cedex 3
France
T +33 (0)2 29 00 11 11
F +33 (0)2 29 00 10 00

Campus de Nantes

4, rue Alfred Kastler
CS 20722
44307 Nantes Cedex 3
France
T +33 (0)2 51 85 81 00
F +33 (0)2 99 12 70 08

Campus de Rennes

2, rue de la Châtaigneraie
CS 17607
35576 Cesson Sévigné Cedex
France
T +33 (0)2 99 12 70 00
F +33 (0)2 51 85 81 99

Site de Toulouse

10, avenue Édouard Belin
BP 44004
31028 Toulouse Cedex 04
France
T +33 (0)5 61 33 83 65

IMT Atlantique

Bretagne-Pays de la Loire
École Mines-Télécom



© IMT Atlantique, 2019
Imprimé à IMT Atlantique
Dépot légal : Septembre 2017
ISSN : 2556-5060